

[문제 회귀 #1]: [서비스/세일즈] 통신 이용요금 예측

구분	상세내용
주제	[서비스/세일즈] 통신 이용 요금 예측
배경	A통신사 고객마케팅팀은 모바일 어플리케이션(이하, 앱)을 통해 고객에게 유용한 정보를 제공하고자 한다. 이를 위해 A 상품을 이용하는 고객들에게 다음달 예측되는 납부예정금액을 알려주는 알림 서비스를 기획하였고, 과거의 요금납부패턴을 AI로 학습시켜 다음달 납부예정금액을 예측하고자 한다. 고객마케팅팀은 본 정보가 앱을 이용하는 고객들을 더 만족시키고, 앱을 이용하는 고객을 늘릴 수 있을 것으로 기대한다
과제명	고객 데이터 분석 및 과거 사용요금 패턴 학습을 통해 각 고객별 다음달 납부예정금액을 예측하는 AI 모델을 만들어보자
데이터 컬럼명	label_fee : 납부 예정금액 customer_class : 고객등급 customer_level : 고객 관리수준 service_category : 서비스 구분 agreement_month : 잔여약정개월수 installment_yn : 할부여부 extra_info1 : 부가정보1 extra_info2 : 부가정보2 prev_fee : 이전 달 납부금액

[문항] 본 과제 해결에 알맞은 알고리즘의 유형을 고르시오.

- (1) 회귀모형
- (2) 분류모형
- (3) 군집모형
- (4) 시계열모형

(정답) (1) 회귀 모형

(해설)

본 과제는 다음 달 납부 예정금액을 예측하는 과제로, 수치형 데이터의 결과값을 가집니다. 이에 수치형 데이터 예측 문제를 해결하기 위한 회귀 모형이 적절합니다.

[문항2] 다음의 수치형 변수 기술통계량을 확인하고, 제3 사분위수(Q3)의 크기가 가장 작은 변수를 고르시오.


- (1) 잔여약정개월수(agreement_month)
- (2) 부가정보1(extra_info1)
- (3) 부가정보2(extra_info2)
- (4) 이전 달 납부금액(prev_fee)

(정답) (2) 부가정보1(extra_info1)

(해설)

데이터 분석-기초정보분석 메뉴에서 “데이터 범위”를 우측 끝까지 드래그 하여 전체 데이터를 선택해주는 것이 가장 중요합니다. 기본 설정으로 분석을 하게 되면 전체 데이터가 아닌 일부 데이터에 대한 통계가 나오기 때문에 잘못된 분석이 될 수 있습니다.

우리의 데이터는 데이터 범위를 끝까지 선택해보면 9,000개의 데이터라는 것을 알 수 있습니다. 이 기준으로 선택지의 4가지 변수를 차례로 분석해보겠습니다. 각 변수의 “분위수” 항목에서 “Q3”를 비교해보시면 됩니다. 선택지 순서대로 확인해보면 19.00, 4.00, 9.00, 68022.50이고 가장 작은 값을 가지는 변수는 ‘부가정보1(extra_info1)’ [4.00] 입니다.




[문항3] '고객등급(customer_class)'이 'VVIP'인 고객의 수를 작성하시오.

(정답) 719

(해설)

데이터 분석-기초정보분석 결과값 중에 '고객등급(customer_class)'의 최빈값 항목을 살펴보면 범주형 변수의 항목 별 갯수를 확인할 수 있습니다. Value가 'VVIP'인 것을 찾아보면 고객의 수가 719인 것을 알 수 있습니다.



[문항4] 다음의 범주형 변수 기술통계량을 확인하고, 특정 범주에 90%이상의 데이터가 몰려 있는 변수를 고르시오.


- (1) 고객등급(customer_class)
- (2) 고객 관리수준(customer_level)
- (3) 서비스 구분(service_category)
- (4) 이전 달 납부금액(prev_fee)

(정답) (3) 서비스 구분(service_category)

(해설)

데이터 분석-기초정보분석 결과값 중에 선택지의 3가지 변수의 최빈값 항목을 살펴보면 각 항목 별 개수뿐

만 아니라 전체 데이터 중에 차지하는 비율(Count(%))도 확인할 수 있습니다. 최빈값 항목의 첫 번째 값이 최빈값을 의미하는데 3가지 변수의 최빈값의 비율은 각각 42.54%, 64.88%, 99.98% 입니다. 따라서 특정 범주에 90%이상의 데이터가 몰려 있는 변수는 '서비스 구분(service_category)' 입니다.



[문항5] 각 '고객등급(customer_class)' 별 '납부 예정금액(label_fee)'을 시각화하고, 제1사분위수(Q1)가 가장 낮은 '고객등급(customer_class)'을 고르시오.

- (1) 일반
- (2) Gold
- (3) Silver
- (4) White


(정답) (1) 일반

(해설)

데이터 분석-시각화 분석 메뉴에서 사분위수 분석을 할 수 있는 시각화 도구는 '박스차트'입니다. 시각화 선택에서 '박스차트'를 선택해주세요. Y컬럼에 분석 대상인 수치형 변수를 선택하고 Hue에는 세분화시켜 볼 범주형 변수를 선택해주면 됩니다. 이 문항에서는 '납부 예정금액(label_fee)'이라는 수치형 변수를 '고객등급(customer_class)'이라는 범주형 변수 별로 세분화시켜야 합니다. 따라서 Y 컬럼 선택에서는 '납부 예정금액(label_fee)'을 고르시고 Hue 컬럼 선택에서는 '고객등급(customer_class)'을 고르시면 됩니다. 이때, 기

초정보분석 때와 마찬가지로 '데이터 범위'를 우측 끝까지 드래그 하셔서 전체 데이터(9,000개)가 선택되도록 해주십시오. 여기까지 설정하셨으면 '조화하기' 버튼을 클릭하여 박스차트 결과를 우측에서 확인할 수 있습니다.

박스차트에서 박스의 상단은 제3사분위수(Q3), 박스의 하단은 제1사분위수(Q1) 값을 의미합니다. 각 등급 별 박스의 하단 값을 비교하면 제1사분위수(Q1)가 가장 낮은 '고객등급(customer_class)'이 '일반'임을 확인할 수 있습니다. 이때, 각 박스가 어떤 '고객등급(customer_class)'을 의미하는지는 우측의 색상 범례를 통해 확인할 수 있습니다.



[문항6] 종속변수를 제외한 모든 변수에 대해 결측치가 있는 경우, 수치형 변수는 중앙값, 범주형 변수는 최빈값으로 결측치를 대체하십시오. 데이터 가공 후, 변환된 '할부여부(installment_yn)'의 최빈값의 개수를 작성하십시오.

- 수치형 변수 : "label_fee", "agreement_month", "extra_info1", "extra_info2", "prev_fee"
- 범주형 변수 : "installment_yn", "customer_class", "customer_level", "service_category"
- 수행 후 [가공 데이터 저장]을 클릭하여 가공된 데이터를 저장하십시오.

(정답) 4611

(해설)


데이터 가공은 '데이터 가공' 메뉴에서 진행합니다. 가공에 앞서 결측치가 있는 변수를 찾아야 하는데요. 앞에서 다룬 기초정보분석 메뉴로 다시 돌아가서 확인하는 방법도 있지만 데이터 가공하기 메뉴

에서 각 변수를 클릭해보면 우측에 기초정보분석에서 본 것과 동일한 분석결과를 확인할 수 있습니다. 결측치 개수는 'missing' 값을 확인하면 되는데, 각 변수에서 'missing'이 0이 아닌 변수를 찾아주 시면 됩니다. 종속변수(label_fee)를 제외한 나머지 변수를 차례대로 확인해보겠습니다.

1. '잔여약정개월수(agreement_month)': 수치형 변수, 결측치 100개 -> 중앙값(median)으 로 결측치 대체
2. '할부여부(installment_yn)': 범주형 변수, 결측치 100개 -> 최빈값(most_frequent)으로 결측치 대체
3. '고객등급(customer_class)': 범주형 변수, 결측치 200개 -> 최빈값(most_frequent)으 로 결측치 대체
4. '이전 달 납부금액(prev_fee)': 수치형 변수, 결측치 300개 -> 중앙값(median)으로 결측 치 대체

예를 들어 '할부여부(installment_yn)'의 결측치를 대체해보도록 하겠습니다. '할부여부 (installment_yn)'를 선택하고 '데이터 가공 실행'의 '결측값 처리' 기능을 사용해보겠습니다. 결측값 을 처리할 수 있는 방식은 목록을 클릭해보면 most_frequent(최빈값), constant(상수값)이 있는데, 문제에서 지정해준 most_frequent(최빈값)를 선택해주면 됩니다. 결측치 처리 방식을 선택한 뒤에는 '보기' 버튼을 눌러 우측에서 결과를 확인한 뒤에 '적용' 버튼을 눌러 변수에 적용까지 해주셔야 합 니다. '적용' 버튼까지 잘 누르셨다면 좌측 변수 목록의 하단에 '변수명_IM'이라는 결측치가 처리된 변 수가 새로 생성된 것을 볼 수 있습니다. 이 새로운 변수를 클릭해보면 'missing'값이 0으로 변한 것 을 확인할 수 있습니다. 변화된 'installment_yn'의 최빈값의 개수는 새로 생성된 'installment_yn_IM' 변수의 최빈값을 확인해주시면 되고 최빈값은 'N'이고 그 개수는 4611개입니 다.

마지막으로 데이터 가공과 결과값 확인이 끝났다면 하단의 '가공 데이터 저장' 버튼을 클릭하여 결과 값을 저장해주시면 됩니다.



[문항기] 3개의 머신러닝 모델을 다음과 같은 설정으로 학습하고, 이 중 설명력(R2)이 평균적으로 가장 높은 모델을 선택하시오.

○ 작업 데이터 선택

- 문항 6번의 데이터 가공을 통해 신규로 저장된 데이터 사용, 별도의 스케일링 처리 불필요.

○ 학습 유형

- 본 과제 해결에 알맞은 알고리즘의 유형을 고려하여 선택

○ ML 모델 선택

- Linear Regression, Decision Tree Regressor, Random Forest Regressor

○ Output 컬럼

- "종속 변수"를 output 컬럼으로 지정

○ Input 컬럼

- 문항 4번의 정답 컬럼은 제외 컬럼으로 지정
- 문항 6번의 결측치 처리에 사용된 '변환하기 전의 변수'는 제외 컬럼으로 지정

○ Data Parameter 설정

- 종속변수의 데이터 유형은 모델 유형에 맞게 설정하고, 나머지는 초기 설정값 사용

O 모델 Parameter 설정

- 초기 설정값 사용

(1) Linear Regression

(2) Decision Tree Regressor

(3) Random Forest Regressor

(정답) (3) Random Forest Regressor

AI모델학습-머신러닝 메뉴로 이동합니다. 문제에서 주어진 가이드에 따라 문항6번에서 가공하고 저장한 데이터('amount_processed')를 '작업 데이터 선택'에서 선택합니다. 다음으로 '학습 유형'은 문항1번에서 확인했듯이 Regression(회귀)를 선택합니다. 학습에 사용할 3가지 모델(Linear Regression, Decision Tree Regressor, Random Forest Regressor)을 'ML 모델 선택'에서 선택합니다. 종속 변수인 'label_fee'를 Input 컬럼 목록에서 선택하여 위쪽 방향 화살표를 클릭하여 Output 컬럼으로 옮겨줍니다. 문항 4번의 정답(특정 범주에 90%이상의 데이터가 몰려 있는 변수)인 '서비스 구분(service_category)' 변수와 문항 6번의 결측치 처리에 사용된 '변환하기 전의 변수'인 '잔여약정개월수(agreement_month)', '할부여부(installment_yn)', '고객등급(customer_class)

s)', '이전 달 납부금액(prev_fee)'을 각각 선택 후 아래쪽 방향 화살표를 클릭하여 제외 컬럼으로 옮겨줍니다. 나머지 파라미터(parameter)는 기본값으로 놔두고 '학습 시작' 버튼을 눌러줍니다. 조금 기다리면 우측에 학습 결과가 나타나는데요. 여러 성능 평가 지표 중에 문항에서 제시한 설명력(R²)이 평균적으로 가장 높은 모델은 R²가 가장 높은 Random Forest Regressor입니다.

Index	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	TT(Sec)
rf	Random Forest Regressor	1821.4875	18917364.6629	4300.6601	0.9664	0.2052	0.0428	10.49
dt	Decision Tree Regressor	1891.0407	25430659.4701	4992.3719	0.9549	0.2152	0.0452	0.18
lr	Linear Regression	3143.3947	26344526.2158	5120.6046	0.9534	0.8846	0.0715	0.04

[문항8] 딥러닝 모델을 다음과 같은 설정으로 학습하고, 학습된 모델의 MSE를 작성하시오.

○ 작업 데이터 선택

- 문항 6번의 데이터 가공을 통해 신규로 저장된 데이터 사용, 별도의 스케일링 처리 불필요

○ Output 컬럼

- "종속 변수"를 output 컬럼으로 지정

○ Input 컬럼

- 문항 4번의 정답 컬럼은 제외 컬럼으로 지정
- 문항 6번의 결측치 처리에 사용된 '변환하기 전의 변수'는 제외 컬럼으로 지정
- 범주형 변수는 데이터 인코더를 sparse로 변경

○ 컬럼 Parameter 설정

- 종속변수의 데이터 유형은 모델 유형에 맞게 설정
- 활성화함수: relu, FC레이어수: 1, FC레이어크: 128, 드롭아웃: 0,

○ 학습 Parameter 설정

- Epochs: 10, Batch Size: 256, 그 외 초기 설정값 사용

○ 답안 작성


- 모델 학습 후 오른쪽 상단의 [모델 저장] 기능을 통해 모델을 저장하시오.
- 정답은 반올림하여 소수점 네 번째 자리까지 작성하시오.

(정답) 0.4820

(해설)

AI모델학습-딥러닝 메뉴로 이동합니다. 문제에서 주어진 가이드에 따라 문항6번에서 가공하고 저장한 데이터('amount_processed')를 '작업 데이터 선택'에서 선택합니다. 다음으로 종속 변수인 'label_fee'를 Input 컬럼 목록에서 선택하여 위쪽 방향 화살표를 클릭하여 Output 컬럼으로 옮겨줍니다. 문항 4번의 정답(특정 범주에 90%이상의 데이터가 몰려 있는 변수)인 '서비스 구분(service_category)' 변수와 문항 6번의 결측치 처리에 사용된 '변환하기 전의 변수' 인 '잔여약정개월수(agreement_month)', '할부여부(installment_yn)', '고객등급(customer_class)', '이전 달 납부금액(prev_fee)'을 각각 선택 후 아래쪽 방향 화살표를 클릭하여 제외 컬럼으로 옮겨줍니다. 다음으로 범주형 변수 3가지(customer_level, installment_yn_IM, customer_class_IM)는 문항 가이드에 따라서 데이터 인코더를 sparse로 설정해야 합니다. 각 범주형 변수를 클릭하고 '컬럼 Parameter 설정'에서 '데이터 인코더'를 sparse로 변경해줍니다. 이번에는 모델 종류를 확인해보겠습니다. 'label_fee'를 선택하여 회귀모델로 설정이 되어 있는지 확인을 해야 합니다. '컬럼 Parameter 설정'에서 '모델 유형'이 regressor인지 확인하고 문항에서 가이드한대로 '활성 함수'가 relu인지도 확인을 해주셔야 합니다. 그리고 문항에서 가이드한대로 FC레이어수: 1, FC레이어크기: 128, 드롭아웃: 0으로 컬럼 Parameter를 설정하고 '학습 Parameter 설정'에서 Epochs: 10, Batch Size: 256로 설정합니다. 나머지 파라미터(parameter)는 기본값으로 놔두고 '학습 시작' 버튼을 눌러줍니다. 조금 기다리면 우측에 학습 결과가 나타납니다. 학습 로그의 가장 마지막에서 모델 성능을 확인할 수 있습니다. 여러 성능 평가 지표 중에 문항에서 제시한 MSE는 0.4820입니다.

마지막으로 오른쪽 상단의 [모델 저장] 기능을 통해 모델을 저장해주시면 됩니다.




[문항9] 문항 8번에서 학습한 딥러닝 모델 분석 결과, '납부 예정금액(label_fee)' 예측에 가장 큰 영향을 주는 변수를 고르시오.

- (1) 이전 달 납부금액(prev_fee_IM)
- (2) 고객등급(customer_class_IM)
- (3) 잔여약정개월수(agreement_month_IM)
- (4) 할부여부(installment_yn_IM)

(정답) (1) 이전 달 납부금액(prev_fee_IM)

시모델활용 메뉴로 이동합니다. '작업 데이터 선택'에서 모델 학습에 사용한 데이터(amount_processed)를 선택하고 아래 '학습 모델 목록'에서는 문항 8번에서 학습하고 저장한 모델을 선택합니다. 예측에 영향을 주는 상위 5개 변수를 확인하기 위해서는 '변수 영향도 확인' 기능을 사용해야 합니다. '변수 영향도 확인' 버튼을 클릭하면 우측에서 그래프 형태로 'label_fee' 변수의 상위 5개 변수의 영향도를 확인할 수 있습니다. 'prev_fee_IM'가 가장 큰 영향을 주는 변수임을 알 수 있습니다.



[문항10] 문항 8번에서 학습한 딥러닝 모델을 활용하여 다음과 같은 조건일 때의 '납부 예정금액 (label_fee)'을 예측하시오.

○ 입력값

- agreement_month: 18

- customer_class: Gold

- customer_level: A

- extra_info1: 0

- extra_info1: 0

- installment_yn_IM: Y

- prev_fee: 48500

○ 정답은 반올림하여 정수로 작성하시오.

(정답) 51668

(해설)

AI모델활용 메뉴로 이동합니다. '작업 데이터 선택'에서 모델 학습에 사용한 데이터(amount_processed)를 선택하고 아래 '학습 모델 목록'에서는 문항8번에서 학습하고 저장한 모델을 선택합니다. 특정 입력값에 대해 결과값을 예측하기 위해서는 '시뮬레이션' 기능을 사용해야 합니다. '시뮬레이션' 버튼을 클릭하면 우측에서 입

력값을 기입하고 예측 결과를 확인할 수 있습니다. 문제에서 제시한 입력값을 기재하면 '납부 예정금액 (label_fee)'의 예측값 51668을 확인할 수 있습니다.

The screenshot shows the 'AI 모델 활용' (AI Model Usage) interface. On the left, under '활용 설정' (Usage Settings), the '작업 데이터 선택' (Job Data Selection) is set to 'amount_processed_...'. The '모델 선택' (Model Selection) is 'amount_processed_...'. The '활용 선택' (Usage Selection) is '모델 학습 결과' (Model Learning Result). The '시뮬레이션' (Simulation) section shows 'agreement_month_IM' as 18, 'customer_class_IM' as 'Gold', 'customer_level' as 'A', 'extra_info1' as 0, 'extra_info2' as 0, 'installment_yn_IM' as 'Y', and 'prev_fee_IM' as 48500. The '시뮬레이션' (Simulation) button is visible. In the center, the '모델 정보' (Model Information) section shows 'Input Features' and 'Output Features'. The 'Output Features' table shows 'label_fee' as a numerical feature. On the right, the '모델 활용 결과' (Model Usage Result) section shows the '시뮬레이션 결과' (Simulation Result) table with a single row for 'label_fee_predictions' with a value of 51668.277344, which is highlighted with a red box.

[문항11] 문항 8번에서 학습한 딥러닝 모델을 고도화하여 MSE를 개선하고, 그 값을 작성하시오.

○ 변수변환, 변수선택, 파라미터 수정 등 자율적으로 수행하시오.

○ 정답은 반올림하여 소수점 네 번째 자리까지 작성하시오.

(정답) 0.4787

(해설)

성능 개선의 경우 여러 가지 경우의 향상 방법이 존재합니다. 본 해설에서는 대표적인 성능 향상 방법 중 하나인 모델의 파라미터 변경을 사용하여 진행해보려고 합니다. AI모델학습-딥러닝 메뉴로 이동합니다. "전체 데이터의 학습 횟수를 의미하는 파라미터"는 'Epochs'이고 이 값을 30으로 지정하고 나머지 설정은 문항 8번과 동일하게 지정해줍니다. 이제 '학습 시작' 버튼을 눌러줍니다. 조금 기다리면 우측에 학습 결과가 나타납니다. 학습 로그의 가장 마지막에서 모델 성능을 확인할 수 있습니다. 여러 성능 평가 지표 중에 문항에서 제시한 MSE는 0.4787입니다. MSE는 오차이기 때문에 값이 작으면 작을수록 성능이 좋은 모델이고 앞선 문항 8번의 결과보다 성능이 개선된 모델임을 알 수 있습니다.

AIDU

새로고침

데이터 초기화

현재 작업공간: New_Workspace_20260310_151250_347...

홈

다운로드

리스트

프로젝트

실행

설정

10156278 2026-03-12

딥러닝 학습

딥러닝 모델을 구성하고 선택한 데이터로 학습을 수행합니다

학습 설정

작업 데이터 선택

amount_processed.csv

데이터 유형

Numerical

학습 파라미터 설정

Epochs

1

1,024

Output 컬럼

label_fee

int64

디코더 선택

regressor

활성화 함수

relu

Batch Size

1

1,024

Input 컬럼

extra_info1

int64

extra_info2

int64

customer_level

object

agreement_mo...

int64

installment...

object

FC 레이어 수

0

10

FC 레이어 크기

1

1,024

Early Stop

1

1,000

Optimizer

adam

Learning Rate

0.001

1

드롭아웃

0

0.99

FC 활성화 함수

relu

재외 컬럼

service_catego...

object

agreement_mo...

int64

installment_yn...

object

학습 시작

10156278 2026-03-12

딥러닝 학습 결과

최초 보기

오류 저장

validation	0.419549	-0.349512	0.419549	0.445692	0.557705
test	0.478733	-0.414889	0.478733	0.496285	0.499337

combined

loss

train	0.488028
validation	0.419549
test	0.478733

Validation loss on combined improved, model saved

Best validation model epoch: 30

Best validation model loss on validation set combined: 0.4195493459701538

Best validation model loss on test set combined: 0.47873321175575256

Finished: amount_processed_d_latest

Saved to: C:\Users\10156278\AppData\Roaming\AIDU\projects\tmp\workspace\works\amount_processed\models\amount_processed_d

evaluation

===== label_fee =====

error: -0.41488858795166

loss: 0.47873321175575256

mean_absolute_error: 0.4962849020957947

mean_squared_error: 0.47873321175575256

r2: 0.4993370771408081

===== combined =====

loss: 0.47873321175575256

페이지 14 / 14