

[문제 분류#2] : [미디어] 고객별 콘텐츠 취향 예측

구분	상세내용
주제	[미디어] 고객별 콘텐츠 취향 예측
배경	VOD 서비스를 제공하는 A미디어사의 마케팅팀은 고객 개인별로 선호하는 장르의 콘텐츠(영화, 드라마 등)를 추천하여 고객 만족도 및 VOD 매출을 높이하고자 한다. 각 고객의 콘텐츠 구매금액 및 구매건수 등의 데이터로 특정 장르에 대한 선호도를 예측하는 AI 모델을 만들면, 각 개인에게 구매 가능성이 높은 콘텐츠를 추천할 수 있을 것이다. 다양한 장르 분류가 있지만, 이번에는 “호러 장르”에 대한 콘텐츠 선호도 예측을 모델링 해보자.
과제명	미디어 콘텐츠 관련 고객 데이터를 기반으로 고객의 호러(horror) 장르 선호여부를 예측하는 AI모델을 만들어 보자.
데이터컬럼명	label_horror : 호러장르 선호여부 total_buy_ol : 총 콘텐츠 구매건수 total_amount : 총 콘텐츠 구매금액 action_amount : 액션 구매금액 drama_amount : 드라마 구매금액 romc_amount : 멜로 구매금액 comedy_amount : 코미디 구매금액 horror_amount : 호러 구매금액 age_group : 연령그룹 customer_type : 고객 유형 sex : 성별

[문제1] 본 과제 해결에 알맞은 알고리즘의 유형을 고르시오.

- (1) 분류모형
- (2) 회귀모형
- (3) 군집모형
- (4) 시계열모형

(정답) (1) 분류모형


(해설) 본 과제는 호러장르 선호여부를 예측하기 위한 모델링을 수행할 것이므로, 범주형 데이터의 결과값을 가집니다. 이에 범주형 데이터 예측 문제를 해결하기 위한 분류모형이 적절합니다.

[문제2] 다음 중 변수의 유형(Data type)이 다른 것을 고르시오.

- (1) 총 콘텐츠 구매건수(total_buy_o)
- (2) 연령그룹(age_group)
- (3) 호러장르 선호여부(label_horror)
- (4) 성별(sex)

(정답) (1) 총 콘텐츠 구매건수(total_buy_o)

(해설)




변수의 유형은 데이터 분석-데이터샘플보기 메뉴에서 데이터 범위를 전체(7,907)로 설정하여 조회한 후, 실제 값들을 통해 확인 가능합니다. '총 콘텐츠 구매건수(total_buy_o)'는 수치형 변수로 구성되어 있고, 나머지 보기들은 범주형 변수로 구성되어 있는 것을 확인할 수 있습니다.

* 데이터 분석-기초 정보 분석 메뉴를 통해서도 판단 가능합니다. 범주형 변수는 Bar 차트로, 수치형 변수는 히스토그램으로 표현되어 있습니다.

[문제3] '총 콘텐츠 구매건수(total_buy_o)'의 기술통계량을 확인하고, 표준편차를 작성하시오.

(정답) 3.13


(해설)



[문제4] '고객 유형(customer_type)'이 '법인사업자'인 고객의 수를 작성하시오

(정답) 183

(해설)



데이터 분석-기초정보분석 메뉴에서 '고객 유형(customer_type)' 중 '법인사업자' 고객의 Count


값은 183 임을 확인할 수 있습니다.

[문제5] '멜로 구매금액(romc_amount)'과 가장 큰 양의 상관관계를 갖는 변수를 고르시오.

- (1) 총 콘텐츠 구매건수(total_buy_ol)
- (2) 총 콘텐츠 구매금액(total_amount)
- (3) 코미디 구매금액(comedy_amount)
- (4) 호러 구매금액(horror_amount)

(정답) (1) 총 콘텐츠 구매건수(total_buy_ol)

(해설)




변수 간 상관관계에 대한 분석은 데이터 분석-시각화 분석에서 시각화 선택 '히트맵' 시각화 기법에서 전체 데이터를 조회하여 확인 가능합니다. 붉은색은 양의 상관관계, 파란색은 음의 상관관계를 의미하며, 색의 진하기가 진할수록 상관관계가 크고, 연할수록 상관관계가 작습니다. 또한, 마우스를 오버랩하여 상관관계의 크기인 상관관계수(z)를 확인할 수 있습니다. '멜로 구매금액(romc_amount)'과 가장 큰 양의 상관관계를 갖는 변수는 '총 콘텐츠 구매건수(total_buy_ol)' 임을 확인할 수 있으며, 상관관계수(z)는 0.1862946 입니다.

[문제6] '액션 구매금액(action_amount)'과 음의 상관관계를 갖는 변수를 고르시오

- (1) 드라마 구매금액(drama_amount)
- (2) 멜로 구매금액(romc_amount)
- (3) 코미디 구매금액(comedy_amount)
- (4) 호러 구매금액(horror_amount)

(정답) (2) 멜로 구매금액(romc_amount)

(해설)



변수 간 상관관계에 대한 분석은 데이터 분석-시각화 분석에서 시각화 선택 '히트맵' 시각화 기법에서 전체 데이터를 조회하여 확인 가능합니다. 붉은색은 양의 상관관계, 파란색은 음의 상관관계를 의미하며, 색의 진하기가 진할수록 상관관계가 크고, 연할수록 상관관계가 작습니다. 또한, 마우스를 오버랩하여 상관관계의 크기인 상관계수(z)를 확인할 수 있습니다. '액션 구매금액(action_amount)'과 음의 상관관계를 갖는 변수는 '멜로 구매금액(romc_amount)'임을 확인할 수 있으며, 상관계수(z)는 -0.03414393 입니다.

[문제7] '호러장르 선호여부(labelLhorror)'가 Y인 사람의 '총 콘텐츠 구매금액(totalAmount)'의 중앙값을 구하시오.


- (1) 1000
- (2) 2500

(3) 4200

(4) 5500

(정답) (3) 4200

(해설)



본 문제에서 주어진 박스차트를 활용하기 위해서는 왼쪽 블레이드에 데이터 분석- 시각화 분석을 선택 후, 시각화 선택 - 박스차트를 선택합니다.

이후, '호러장르 선호여부(label_horror)'에 따른 '총 콘텐츠 구매금액(total_amount)'의 중앙값을 구하기 위해 아래와 같이 X컬럼/Y컬럼/Hue컬럼/데이터 범위를 선택합니다.

X 컬럼 선택 : label_horror

Y 컬럼 선택 : total_amount

Hue 컬럼 선택 : label_horror(선택사항)_색 표현을 위함

데이터 범위 : 7907(전범위)

박스차트 결과가 나오면 확대를 진행하고 커서를 대어 값을 확인할 수 있습니다.


Y의 박스차트를 확인해보면 중앙값(median)은 4,200이라는 것을 알 수 있습니다.

(참고로 N의 박스차트 중앙값은 5,500입니다.)

[문제8] '호러장르 선호여부(label_horror)'가 Y인 사람의 '호러 구매금액(horror_amount)'의 중앙값을 구하시오.

(정답) 2500

(해설)



본 문제에서 주어진 박스차트를 활용하기 위해서는 왼쪽 블레이드에 데이터 분석- 시각화 분석을 선택 후, 시각화 선택 - 박스차트를 선택합니다.

이후, '박스차트를 활용하여 '호러장르' 선호여부(label_horror)'가 Y인 사람의 '호러' 구매금액(horror_amount)'의 중앙값을 구하기 위해 아래와 같이 X컬럼/Y컬럼/Hue컬럼/데이터 범위를 선택합니다.

X 컬럼 선택 : label_horror

Y 컬럼 선택 : horror_amount

Hue 컬럼 선택: label_horror(선택사항)_색 표현을 위함

데이터 범위 : 7907(전범위)

박스차트 결과가 나오면 확대를 진행하고 커서를 대어 값을 확인할 수 있습니다.


Y의 박스차트를 확인해보면 중앙값(median)은 2,500이라는 것을 알 수 있습니다.

[문제9] 종속변수를 제외한 모든 변수에 대해 결측치가 있는 경우, 수치형 변수는 중앙값, 범주형 변수는 최빈값으로 결측치를 대체하시오. 데이터 가공 후, 변환된 '연령그룹(age_group)'의 최빈값의 개수를 작성하시오.

- 수치형 변수 : "total_buy_ol", "total_amount", "action_amount", "drama_amount", "romc_amount", "comedy_amount", "horror_amount"
- 범주형 변수 : "label_horror", "age_group", "customer_type", "sex"
- 수행 후 [가공 데이터 저장]을 클릭하여 가공된 데이터를 저장하시오.
- 0000 형식으로 작성하시오. 예시) 1234

(정답) 1262

(해설)



데이터에 결측치가 존재하는 경우, “데이터 가공” 탭을 통해 원하는 컬럼을 선택한 후 결측치 데이터를 특정 값으로 대체할 수 있습니다. 컬럼별 통계 정보를 확인하면, ‘연령그룹(age_group)’ 컬럼에서만 missing(결측치)값이 존재하는 것을 확인할 수 있습니다. ‘연령그룹(age_group)’ 컬럼은 범주형 변수임에 따라, 해당 컬럼의 결측값 처리는 최빈값(most_frequent)으로 설정하여 변경 처리합니다. 결측치가 대체된 age_group_IM 컬럼의 기술통계량을 확인하면, 최빈값인 ‘A07’의 개수는 1262 임을 확인할 수 있습니다. 마지막으로 데이터 가공과 결과값 확인이 끝났다면 하단의 ‘가공 데이터 저장’ 버튼을 클릭하여 결과값을 저장해주시면 됩니다.


[문제10] ‘연령그룹(age_group_IM)’ 별 ‘드라마 구매금액(drama_amount)’을 시각화하고, ‘연령그룹(age_group_IM)’ A15의 IQR의 Q3 값을 작성하시오.

○ 작업 데이터 선택

- 문항 9번의 데이터 가공을 통해 신규로 저장된 데이터 사용, 별도의 스케일링 처리 불필요.

(정답) 7750

(해설)



데이터분석-시각화 분석 메뉴에서 박스차트를 활용하여 사분범위를 확인할 수 있습니다. 문제에서 주어진 조건에 따라 X컬럼과 Y컬럼을 선택하고, 작업 데이터 범위를 전체로 설정하여 조회합니다. 우측 시각화 결과 영역의 박스차트에서 X컬럼별 '드라마 구매금액(drama_amount)' 값의 분포를 확인할 수 있습니다.

문제에서 요청한 '연령그룹(age_group_IM)' A15에 커서를 두면, A15의 Q3(삼분위수)는 7750임을 확인할 수 있습니다.


[문제11] '연령그룹(age_group_IM)' 별 '드라마 구매금액(drama_amount)'을 시각화하고, '연령그룹(age_group_IM)' A04의 이상치 중 가장 작은 값을 작성하시오.

○ 작업 데이터 선택

- 문항 9번의 데이터 가공을 통해 신규로 저장된 데이터 사용, 별도의 스케일링 처리 불필요

(정답) 6400

(해설)



데이터분석-시각화 분석 메뉴에서 박스차트를 활용하여 사분범위와 이상치를 확인할 수 있습니다. 문제에서 주어진 조건에 따라 X컬럼과 Y컬럼을 선택하고, 작업 데이터 범위를 전체로 설정하여 조회합니다. 우측 시각화 결과 영역의 박스차트에서 X컬럼별 IQR과 이상치 분포를 확인할 수 있습니다. 문제에서 요청한 '연령그룹(age_group_IM)' A04에 커서를 두면, A04의 Upper fence*는 5000. Upper fence를 벗어난 이상치 중 최소값은 6400임을 확인할 수 있습니다.


*Upper fence(이상치 식별을 위한 상단 경계) = $Q3 + 1.5 * IQR$

[문제12] '고객 유형(customer_type)' 별 '드라마 구매금액(drama_amount)'을 시각화하고, '고객 유형(customer_type)' 공공기관의 이상치 중 가장 작은 값을 작성하시오.

○ 정답은 00.0k 형식으로 작성하시오. 예시) 22.3k

(정답) 12.9k

(해설)



데이터분석-시각화 분석 메뉴에서 박스차트를 활용하여 사분범위와 이상치를 확인할 수 있습니다. 문제에서 주어진 조건에 따라 X컬럼과 Y컬럼을 선택하고, 작업 데이터 범위를 전체로 설정하여 조회합니다. 우측 시각화 결과 영역의 박스차트에서 X컬럼별 IQR과 이상치 분포를 확인할 수 있습니다. 문제에서 요청한 '고객 유형(customer_type) 공공기관'에 커서를 두면, 공공기관의 Upper fence는 10k. Upper fence를 벗어난 이상치 중 최소값은 12.9k임을 확인할 수 있습니다.


*Upper fence(이상치 식별을 위한 상단 경계) = $Q3 + 1.5 * IQR$

[문제13] '멜로 구매금액(romc_amount)'이 '0~100'에 속하는 고객 중 '성별(sex)'이 'M(남성)'인 고객의 수를 작성하시오.

(정답) 3294

(해설)

데이터 분석-시각화 분석에서 시각화 선택 '분포차트' 시각화 기법을 통해 수치형 변수의 분포를 확인할 수 있습니다. Hue 컬럼의 색상으로 표현할 범주형 변수를 지정하면, 수치형 변수의 각 구간에서 범주형 변수의 각 범주들이 얼마나 해당하는지를 확인할 수 있습니다. 문제에서 제시한 '멜로 구매금액(romc_amount)'이 '0~100'에 속하는 고객 중 '성별(sex)'이 'M(남성)'인 고객은 파란색으로 확인할 수 있고, 해당하는 고객의 수는 3294임을 확인할 수 있습니다.



[문제14] 머신러닝 모델을 다음과 같은 설정으로 학습하고, Random Forest의 재현율(Recall)을 작성하십시오.

- 작업 데이터 선택
 - 문항 9번 데이터 가공을 통해 신규 저장된 데이터 사용, 별도 스케일링 처리 불필요
- 학습 유형
 - 본 과제 해결에 알맞은 알고리즘의 유형을 고려하여 선택
- ML 모델 선택
 - KNN, Decision Tree, Random Forest
- Output 컬럼
 - "종속 변수"를 output 컬럼으로 지정
- Input 컬럼
 - 문항 9번의 결측치 처리에 사용된 '변환하기 전의 변수'는 제외 컬럼으로 지정
- DataParameter 설정
 - 데이터 유형은 모델 유형에 맞게 설정하고, 나머지는 초기 설정값 사용
- 모델 Parameter 설정
 - 초기 설정값 사용

(정답) 0.8649

(해설)

머신러닝 학습 결과

Index	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC	TT (Sec)
knn	K Nearest Neighbor	0.9536	0.9130	0.8607	0.9519	0.9518	0.7678	0.7715	1.18
rf	Random Forest	0.9508	0.9328	0.8649	0.9493	0.9497	0.7600	0.7616	3.30
dt	Decision Tree	0.9418	0.8480	0.8515	0.9407	0.9409	0.7205	0.7218	0.18

주어진 데이터를 활용하여, 시모델 학습-머신러닝 학습 메뉴에서 머신러닝 모델 학습을 수행할 수 있습니다. 문제에서 주어진 조건에 따라 작업 데이터 선택, 컬럼 및 파라미터를 설정하고 학습을 수행하면, 일정 시간이 경과되어 학습이 완료된 후 우측 학습결과 영역에서 만들어진 모델의 재현율(Recall)을 확인할 수 있습니다.

생성한 모델이 '호러장르 선호여부(label_horror)'를 예측함에 대한 학습 정확도(Accuracy)는 0.8649 (반올림 후 소수점 네 번째 자리까지 작성)임을 확인할 수 있습니다. 마지막으로 오른쪽 상단의 [모델 저장] 기능을 통해 모델을 저장해주시면 됩니다.


[문제15] 딥러닝 모델을 다음과 같은 설정으로 학습하고, 학습된 모델의 Accuracy를 작성하시오

- 작업 데이터 선택
 - 문항 9번 데이터 가공을 통해 신규 저장된 데이터 사용, 별도 스케일링 처리 불필요
- Output 컬럼
 - "종속 변수"를 output 컬럼으로 지정
- Input 컬럼
 - 문항 9번의 결측치 처리에 사용된 '변환하기 전의 변수'는 제외 컬럼으로 지정
 - 범주형 변수는 데이터 인코더를 sparse로 변경
- 컬럼 Parameter 설정
 - 종속변수의 데이터 유형은 모델 유형에 맞게 설정
 - 활성화함수: softmax, FC레이어수: 1, FC레이어크기: 256, 드롭아웃: 0,
- 학습 Parameter 설정
 - Epochs: 20, Batch Size: 256, 그 외 초기 설정값 사용
- 답안 작성
 - 모델 학습 후 오른쪽 상단의 [모델 저장] 기능을 통해 모델을 저장하시오.

- 정답은 반올림하여 소수점 네 번째 자리까지 작성하시오.

(정답) 0.9536

(해설)



주어진 데이터를 활용하여, AI모델 학습-딥러닝 학습 메뉴에서 딥러닝 모델 학습을 수행할 수 있습니다. 문제에서 주어진 조건에 따라 작업 데이터 선택, 컬럼 및 파라미터를 설정하고 학습을 수행하면, 일정 시간이 경과되어 학습이 완료된 후 우측 학습결과 영역에서 만들어진 모델의 정확도(Accuracy)를 확인할 수 있습니다. 생성한 모델이 '호러장르 선호여부(label_horror)'를 예측함에 대한 학습 정확도(Accuracy)는 0.9536(반올림 후 소수점 네 번째 자리까지 작성)임을 확인할 수 있습니다. 마지막으로 오른쪽 상단의 [모델 저장] 기능을 통해 모델을 저장해주시면 됩니다.