

[문제 분류#3]: [미디어] 고객별 콘텐츠 취향 예측

구분	상세내용
주제	[미디어] 고객별 콘텐츠 취향 예측
배경	VOD 서비스를 제공하는 A미디어사의 마케팅팀은 고객 개인별로 선호하는 장르의 콘텐츠(영화, 드라마 등)를 추천하여 고객 만족도 및 VOD 매출을 높이하고자 한다. 각 고객의 콘텐츠 구매금액 및 구매건수 등의 데이터로 특정 장르에 대한 선호도를 예측하는 AI 모델을 만들면, 각 개인에게 구매 가능성이 높은 콘텐츠를 추천할 수 있을 것이다. 다양한 장르 분류가 있지만, 이번에는 “호러 장르”에 대한 콘텐츠 선호도 예측을 모델링 해보자.
과제명	미디어 콘텐츠 관련 고객 데이터를 기반으로 고객의 호러(horror) 장르 선호여부를 예측하는 AI모델을 만들어 보자.
데이터컬럼명	label_horror : 호러장르 선호여부 total_buy_ol : 총 콘텐츠 구매건수 total_amount : 총 콘텐츠 구매금액 action_amount : 액션 구매금액 drama_amount : 드라마 구매금액 romc_amount : 멜로 구매금액 comedy_amount : 코미디 구매금액 horror_amount : 호러 구매금액 age_group : 연령그룹 customer_type : 고객 유형 sex : 성별

[문제1] 본 과제 해결에 알맞은 알고리즘의 유형을 고르시오.

- (1) 분류모형
- (2) 회귀모형
- (3) 군집모형
- (4) 시계열모형

(정답) (1) 분류모형

(해설)

본 과제는 호러장르 선호여부를 예측하기 위한 모델링을 수행할 것이므로, 범주형 데이터의 결과값을 가집니다. 이에 범주형 데이터 예측 문제를 해결하기 위한 분류모형이 적절합니다.

[문제2] 본 과제를 해결하기 위한 종속변수를 고르시오

- (1) 호러장르 선호여부(label_horror)

- (2) 총 콘텐츠 구매건수(total_buy_ol)
- (3) 총 콘텐츠 구매금액(total_amount)
- (4) 액션 구매금액(action_amount)

(정답) (1) 호러장르 선호여부(label_horror)


(해설)

본 과제는 호러장르 선호여부를 예측하기 위한 모델링을 수행할 것입니다. 따라서 호러장르 선호여부를 나타내는 '호러장르 선호여부(label_horror)'를 종속변수로 설정하는 것이 바람직합니다.

[문제3] 수치형 변수와 범주형 변수 개수의 차이를 작성하시오.

(정답) 3

(해설)



데이터 분석-기초정보분석 메뉴에서 Numeric 유형은 7개, Object 유형은 4개 확인할 수 있습니다.


[문제4] '총 콘텐츠 구매건수(total_buy_ol)'의 기술통계량을 확인하고, 가장 큰 값을 지니는 통계량을 고르시오.

- (1) 평균값
- (2) 중위수
- (3) 표준편차

(4) 제3사분위수

(정답) (3) 표준편차

(해설)




데이터 분석-기초정보분석 메뉴에서 '총 콘텐츠 구매건수(total_buy_ol)' 변수의 각 기술통계량의 값을 확인합니다. 평균값(mean)은 '2.2', 중위수(median)은 '1.00', 표준편차(sd)는 '3.13', 제3사분위수(Q3)는 '3.00'으로, 보기 중 가장 큰 값을 지니는 통계량은 표준편차(sd)임을 확인할 수 있습니다.

[문제5] '호러 구매금액(horror_amount)'과 가장 큰 양의 상관관계를 갖는 변수를 구하시오.

- (1) 총 콘텐츠 구매건수(total_buy_ol)
- (2) 총 콘텐츠 구매금액(total_amount)
- (3) 액션 구매금액(action_amount)
- (4) 드라마 구매금액(drama_amount)

(정답) (1) 총 콘텐츠 구매건수(total_buy_ol)

(해설)




변수 간 상관관계에 대한 분석은 데이터 분석-시각화 분석에서 시각화 선택 '히트맵' 시각화 기법에서 전체 데이터를 조회하여 확인 가능합니다. 붉은색은 양의 상관관계, 파란색은 음의 상관관계를 의미하며, 색의 진하기가 진할수록 상관관계가 크고, 연할수록 상관관계가 작습니다. 또한, 마우스를 오버랩하여 상관관계의 크기인 상관계수(z)를 확인할 수 있습니다. '호러 구매금액(horror_amount)'과 가장 큰 양의 상관관계를 갖는 변수는 '총 콘텐츠 구매건수(total_buy_ol)'임을 확인할 수 있으며, 상관계수(z)는 0.189013 입니다.

[문제6] '고객 유형(customer_type)'이 개인일 때, '드라마 구매금액(drama_amount)'이 00보다 큰 수치이면 IQR기준 이상치라고 판단한다. 다음 빈칸에 들어가는 수치를 작성하시오.

(정답) 6000

(해설) 데이터의 IQR(Interquartile Range) 관련 정보를 파악하기 위해서는, 데이터 분석 - 시각화 분석의 박스차트(Box plot)를 활용할 수 있습니다. X 컬럼을 customer_type, y 컬럼을 drama_amount로 선택하고, 데이터 범위를 최대로 지정하여 조회합니다. customer_type 가 '개인'인 박스 차트에 마우스를 올려보면, 최대치(max)와, 이상치가 아닌 값의 상한선 (upper fence), 3분위점(q3) 등의 정보를 확인할 수 있습니다.




[문제기] '호러장르 선호여부(label_horror)'가 'Y'일 때, '총 콘텐츠 구매건수(total_buy_ol)'의 이상치가 아닌 값의 상한선을 고르세요

- (1) 2
- (2) 4
- (3) 6
- (4) 8

(정답) (3) 6

(해설)

데이터의 이상치를 파악하기 위해서는, 데이터 분석 - 시각화 분석의 박스차트(Box plot)를 활용할 수 있습니다. '호러장르 선호여부(label_horror)'가 Y인 그룹에서 '총 콘텐츠 구매건수(total_buy_ol)'의 이상치 정보를 파악하기 위해서, X 컬럼을 label_horror, y 컬럼을 total_buy_ol로 선택하고, 데이터 범위를 최대로 지정하여 조회합니다. label_horror가 Y인 박스 차트에 마우스를 올려보면, 최대치(max)와, 이상치가 아닌 값의 상한선 (upper fence), 3분위점(q3) 등의 정보를 확인할 수 있습니다.




[문제8] '고객 유형(customer_type)'별 '총 콘텐츠 구매건수(totalbuy_ol)'를 시각화하고, '총 콘텐츠 구매 건수(totalbuy_ol)'가 '1'건인 고객이 가장 많이 속한 '고객 유형(customer_type)'의 구간을 고르시오.

- (1) 개인
- (2) 개인사업자
- (3) 법인사업자
- (4) 공공기관

(정답) 개인


(해설) 데이터의 분포를 시각화하기 위해서는 데이터 분석 - 시각화 분석의 분포차트(Density plot)를 활용할 수 있습니다. X 컬럼을 total_by_ol, Hue 컬럼을 customer_type으로 선택하고, 데이터 범위를 최대로 지정하여 조회합니다. 총 콘텐츠 구매건수(total_by_ol)가 '1'건인 고객을 자세히 확인하기 위해, X축 최소값과 최대값을 적당한 값으로 지정합니다. customer_type 가 '개인'인 유형이 가장 많은 분포를 보이는 것을 확인할 수 있습니다.



[문제9] '멜로 구매금액(romc_amount)'이 '0~100'에 속하는 고객 중 '성별(sex)'이 'F(여성)'인 고객의 수를 작성하시오.

(정답) 3345

(해설)



데이터 분석-시각화 분석에서 시각화 선택 '분포차트' 시각화 기법을 통해 수치형 변수의 분포를 확인


할 수 있습니다. Hue 컬럼의 색상으로 표현할 범주형 변수를 지정하면, 수치형 변수의 각 구간에서 범주형 변수의 각 범주들이 얼마나 해당하는지를 확인할 수 있습니다. 문제에서 제시한 '멜로 구매금액(romc_amount)'이 '0~100'에 속하는 고객 중 '성별(sex)'이 'F(여성)'인 고객은 붉은색으로 확인할 수 있고, 해당하는 고객의 수는 3345임을 확인할 수 있습니다.

[문제10] 종속변수를 제외한 모든 변수에 대해 결측치가 있는 경우, 수치형 변수는 중앙값, 범주형 변수는 최빈값으로 결측치를 대체하시오. 데이터 가공 후, 변환된 '연령그룹(age_group)'의 최빈값의 비율(%)을 작성하시오.

- 수치형 변수 : "total_buy_ol", "total_amount", "action_amount", "drama_amount", "romc_amount", "comedy_amount", "horror_amount"
- 범주형 변수 : "label_horror", "age_group", "customer_type", "sex"
- 수행 후 [가공 데이터 저장]을 클릭하여 가공된 데이터를 저장하시오.
- 00.00 형식으로 작성하시오. 예시) 12.34

(정답) 15.96

(해설)



데이터에 결측치가 존재하는 경우, "데이터 가공"탭을 통해 원하는 컬럼을 선택한 후 결측치 데이터를 특정 값으로 대체할 수 있습니다. 컬럼별 통계 정보를 확인하면, '연령그룹(age_group)' 컬럼에서만 missing(결측치)값이 존재하는 것을 확인할 수 있습니다. '연령그룹(age_group)' 컬럼은 범주형 변수임에 따라, 해당 컬럼의 결측값 처리는 최빈값(most_frequent)으로 설정하여 변경 처리합니다. 결측치가 대체된 age_group_IM 컬럼의 기술통계량을 확인하면, 최빈값인 'A07'의 비율인


Count(%) 값은 15.96 임을 확인할 수 있습니다. 마지막으로 데이터 가공과 결과값 확인이 끝났다면 하단의 '가공 데이터 저장' 버튼을 클릭하여 결과값을 저장해주시면 됩니다.

[문제11] 딥러닝 모델을 다음과 같은 설정으로 학습하고, 학습된 모델의 Accuracy를 작성하시오

- 작업 데이터 선택
 - 문항 10번의 데이터 가공을 통해 신규로 저장된 데이터 사용, 별도의 스케일링 처리 불필요
- Output 컬럼
 - "종속 변수"를 output 컬럼으로 지정
- Input 컬럼
 - 문항 10번의 결측치 처리에 사용된 '변환하기 전의 변수'는 제외 컬럼으로 지정
 - 범주형 변수는 데이터 인코더를 sparse로 변경
- 컬럼 Parameter 설정
 - 종속변수의 데이터 유형은 모델 유형에 맞게 설정
 - 활성화함수: softmax, FC레이어수: 1, FC레이어크기: 256, 드롭아웃: 0,
- 학습 Parameter 설정
 - Epochs: 20, Batch Size: 256, 그 외 초기 설정값 사용
- 답안 작성
 - 모델 학습 후 오른쪽 상단의 [모델 저장] 기능을 통해 모델을 저장하시오.
 - 정답은 반올림하여 소수점 네 번째 자리까지 작성하시오.

(정답) 0.9536

(해설)



주어진 데이터를 활용하여, 시모델 학습-딥러닝 학습 메뉴에서 딥러닝 모델 학습을 수행할 수 있습니다


다. 문제에서 주어진 조건에 따라 작업 데이터 선택, 컬럼 및 파라미터를 설정하고 학습을 수행하면, 일정 시간이 경과되어 학습이 완료된 후 우측 학습결과 영역에서 만들어진 모델의 정확도(Accuracy)를 확인할 수 있습니다. 생성한 모델이 '호러장르 선호여부(label_horror)'를 예측함에 대한 학습 정확도(Accuracy)는 0.9536(반올림 후 소수점 네 번째 자리까지 작성) 임을 확인할 수 있습니다. 마지막으로 오른쪽 상단의 [모델 저장] 기능을 통해 모델을 저장해주시면 됩니다.

[문제12] 문항 11번에서 학습한 딥러닝 모델 분석 결과, '호러장르 선호여부(label_horror)' 예측에 영향을 주는 상위 5개의 변수에 해당하는 변수를 고르시오.

- (1) 코미디 구매금액(comedy_amount)
- (2) 드라마 구매금액(drama_amount)
- (3) 총 콘텐츠 구매금액(totalAmount)
- (4) 멜로 구매금액(romc_amount)

(정답) (2) 총 콘텐츠 구매금액(totalAmount)

(해설)



생성한 모델에 대한 다양한 활용을 “시모델 활용”을 통해 수행할 수 있습니다. 작업 데이터는 전처리 한 데이터로 선택하고, 학습하여 저장한 모델을 선택한 뒤 “변수 영향도 확인”을 선택하면, 생성한 모델이 출력변수인 '호러장르 선호여부(label_horror)'를 예측하는데 영향을 주는 상위 5개 변수를 확인할 수 있습니다. 문제에서 제시한 보기 중, 상위 5개 변수에 해당하는 것은 총 콘텐츠 구매금액(totalAmount)인 것을 알 수 있습니다.

[문제13] 문항 11번에서 학습한 딥러닝 모델을 활용하여 다음과 같은 조건일 때의 '호러장르 선호여부 (label_horror)'를 예측하시오

- action_amount: 2500
- age_group_IM: A07
- comedy_amount: 0
- customer_type: 개인
- drama_amount: 2500
- horror_amount: 3000
- romc_amount: 0
- sex: M
- total_amount: 8000
- total_buy_ol: 3

(1) Y(선호함)

(2) N(선호하지 않음)

(정답) (1) Y(선호함)

(해설)

The screenshot shows the AIDU AI Model Usage interface. The 'Simulation Results' (모델 활용 결과) section is highlighted with a red box. It displays the following results:

시뮬레이션 결과	값
label_horror_predictions	Y
label_horror_probabilities	0.004731521941721435, 0.17952923476696014, 0.8157333332295082
label_horror_probability	0.815739
label_horror_probabilities_<UNK>	0.004732
label_horror_probabilities_N	0.179529
label_horror_probabilities_Y	0.815739

“시모델 활용” 에서 생성한 모델에 임의의 값을 넣어 어떤 결과가 출력되는지를 시뮬레이션 해 볼 수

있습니다. “시뮬레이션”을 선택하고, 문제에서 제시하는 대로 각 변수별 값을 입력하면 우측 하단에서 시뮬레이션 결과가 도출됩니다. 주어진 입력값들에 대한 '호러장르 선호여부(label_horror)'에 대한 예측 시뮬레이션 결과는 label_horror_predictions이며, 'Y(선호함)'으로 예측됨을 확인할 수 있습니다.

[문제14] 3개의 머신러닝 모델을 다음과 같은 설정으로 학습하고, 이 중 Precision 기준 성능이 평균적으로 가장 좋은 것을 고르시오

○ 작업 데이터 선택 : 문항 10번의 데이터 가공을 통해 신규로 저장된 데이터 사용, 별도의 스케일링 처리 불필요.

○ 학습 유형 : 본 과제 해결에 알맞은 알고리즘의 유형을 고려하여 선택

○ ML 모델 선택 : Logistic Regression, KNN, Random Forest

○ Input 컬럼 : 문항 10번의 결측치 처리에 사용된 '변환하기 전의 변수'는 제외 컬럼으로 지정

○ Output 컬럼 : "종속 변수"를 output 컬럼으로 지정

○ DataParameter 설정 : 데이터 유형은 모델 유형에 맞게 설정하고, 나머지는 초기 설정값 사용

○ 모델 Parameter 설정 : 초기 설정값 사용


(1) Logistic Regression

(2) KNN

(3) Random Forest

(정답) (1) KNN

(해설)



주어진 데이터를 활용하여, 시모델 학습-머신러닝 학습 메뉴에서 머신러닝 모델 학습을 수행할 수 있습니다. 문제에서 주어진 조건에 따라 작업 데이터 선택, 컬럼 및 파라미터를 설정하고, 3개의 머신러닝 모델(Logistic Regression, K Nearest Neighbor, Random Forest)을 선택하여 학습을 시작하면, 일정 시간이 경과되어 학습이 완료된 후 우측 학습결과 영역에서 각 모델별 평가 지표들을 확인할 수 있습니다. Precision 기준으로 성능이 가장 좋은 모델은 K Nearest Neighbor 인 것을 확인할 수 있습니다.

[문제15] 3개의 머신러닝 모델을 다음과 같은 설정으로 학습하고, 이 중 F1 Score 기준 성능이 평균적으로 가장 좋은 것을 고르시오

- 작업 데이터 선택 : 문항 10번의 데이터 가공을 통해 신규로 저장된 데이터 사용, 별도의 스케일링 처리 불필요.
- 학습 유형 : 본 과제 해결에 알맞은 알고리즘의 유형을 고려하여 선택
- ML 모델 선택 : Logistic Regression, Decision Tree, Random Forest
- Input 컬럼 : 문항 10번의 결측치 처리에 사용된 '변환하기 전의 변수'는 제외 컬럼으로 지정
- Output 컬럼 : "종속 변수"를 output 컬럼으로 지정
- Data Parameter 설정 : 데이터 유형은 모델 유형에 맞게 설정하고, 나머지는 초기 설정값 사용
- 모델 Parameter 설정 : 초기 설정값 사용

(1) Logistic Regression

(2) Decision Tree

(3) Random Forest

(정답) (3) Random Forest

(해설)

머신러닝 학습 결과

Index	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC	TT (Sec)
rf	Random Forest	0.9508	0.9328	0.8649	0.9493	0.9497	0.7600	0.7616	2.95
lr	Logistic Regression	0.9434	0.9172	0.8120	0.9406	0.9394	0.6999	0.7110	0.32
dt	Decision Tree	0.9418	0.8480	0.8515	0.9407	0.9409	0.7205	0.7218	0.22

주어진 데이터를 활용하여, AI모델 학습-머신러닝 학습 메뉴에서 머신러닝 모델 학습을 수행할 수 있습니다. 문제에서 주어진 조건에 따라 작업 데이터 선택, 컬럼 및 파라미터를 설정하고, 3개의 머신러닝 모델(Logistic Regression, Decision Tree, Random Forest)을 선택하여 학습을 시작하면, 일정 시간이 경과되어 학습이 완료된 후 우측 학습결과 영역에서 각 모델별 평가 지표들을 확인할 수 있습니다. F1 Score 기준으로 성능이 가장 좋은 모델은 Random Forest Classifier 인 것을 확인할 수 있습니다.